



TC

ÜSKÜDAR ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

BİYOİNFORMATİK (TEZLİ) YÜKSEK LİSANS PROGRAMI

FİNAL ÖDEVİ

Radyomik Özellikler Kullanılarak Papilödem Sınıflandırması: Makine

Öğrenmesi Tabanlı Bir Karar Destek Sistemi

Aslı ÇALIŞKANOĞLU

DANIŞMAN

Dr. Öğr. Üyesi GÖKALP TULUM

İSTANBUL-2026

1. GİRİŞ	1
1.1. Papilödem ve Radyomik Analiz	1
1.2. Çalışmanın Amacı ve Önemi	1
1.3. Problemin Tanımı	1
2. VERİ SETİ VE ÖZELLİKLERİ	2
2.1. Veri Setinin Yapısı	2
2.2. Radyomik Özelliklerin Tanımı	2
3. METODOLOJİ (YAPAY ZEKA PİPELINE'İ)	3
3.1. Veri Ön İşleme	3
3.2. Özellik Seçimi (MRMR)	4
3.3. Hiperparametre Optimizasyonu	4
3.4. Çapraz Doğrulama	5
3.5. Modelleme Yaklaşımı	5
3.6. Kalibrasyon ve Ensemble	6
4. BULGULAR (SONUÇLAR)	7
4.1. Model Performans Metrikleri	7
4.2. Görsel Sonuçlar	8
4.3. İstatistiksel Analiz	9
5. TARTIŞMA	10
5.1. Analiz Sorularının Yanıtları	10
5.2. İstatistiksel Değerlendirme Yorumları	11
6. SHAP ANALİZİ	12
7. SONUÇ	13
8. KAYNAKÇA	1

1. Giriş

1.1. Papilödem ve Radyomik Analiz Hakkında Genel Bilgi

Papilödem, intrakraniyal basınç artışına bağlı olarak optik diskin ödemlenmesi olarak tanımlanan ve klinik olarak ciddi sonuçlar doğurabilen oftalmolojik bir durumdur.

Erken teşhis, hastaların tedavi süreçlerinde kritik bir öneme sahiptir. Tıbbi görüntüleme teknolojilerinin gelişmesiyle birlikte, görüntüler üzerinden sayısal verilerin elde edilmesini sağlayan **radyomik (radiomics)** analizler, hastalık tanısında yapay zeka destekli karar mekanizmaları için güçlü bir veri kaynağı haline gelmiştir. Radyomik özellikler, çıplak gözle görülemeyen doku değişimlerini sayısal değerlere dönüştürerek, hastalık teşhisinde daha hassas ve objektif sonuçlar elde edilmesine olanak tanımaktadır.

1.2. Çalışmanın Amacı ve Önemi


Bu çalışmanın temel amacı, sunulan radyomik veri setlerini kullanarak “Normal” ve “Papilödem” sınıflarını birbirinden ayıran, yüksek doğruluklu bir makine öğrenmesi pipeline’ı geliştirmektir. Çalışmada, veri sızıntısını (data leakage) engelleyen, hasta seviyesinde ayrıştırma yapan ve özellik seçiminde MRMR gibi gelişmiş yöntemleri kullanan bir metodoloji benimsenmiştir. Bu proje, sadece bir sınıflandırma problemi çözmeyi değil, aynı zamanda radyomik verilerin klinik karar destek sistemlerinde nasıl daha güvenilir bir şekilde kullanılabileceğini bilimsel bir çerçevede incelemeyi hedeflemektedir.

1.3. Problemin Tanımı (İkili Sınıflandırma)

Çalışma, ikili sınıflandırma (binary classification) problemine odaklanmaktadır. 746 adet radyomik özellikten oluşan veri seti üzerinde geliştirilecek olan model, bir örneğin "Normal" (Etiket: 0) veya "Papilödem" (Etiket: 1) sınıfına ait olup olmadığını tahmin edecektir. Geliştirilen modelin başarısı; doğruluğun (accuracy) yanı sıra hassasiyet (precision), duyarlılık (recall), F1-skoru ve ROC-AUC gibi temel performans metrikleri ile değerlendirilecek; model kalibrasyonu ve ensemble teknikleri ile tahmin sonuçlarının güvenilirliği artırılacaktır.

2.1. Veri Setinin Yapısı

Bu çalışmada kullanılan veri seti, optik disk görüntüleri üzerinden elde edilen radyomik özelliklerden oluşmaktadır. Çalışma kapsamında iki temel veri kaynağı sağlanmıştır: normal_radiomics.csv (sağlıklı kontroller) ve papilodem_radiomics.csv (papilödem vakaları). Veri setlerinin birleştirilmesi aşamasında, her bir örneğe ait sınıf etiketi; normal vakalar için **"0"**, papilödem vakaları için ise **"1"** olarak atanmıştır. Veri seti, hasta düzeyinde gruplandırılarak düzenlenmiş olup, aynı hastaya ait örneklerin eğitim ve test süreçlerinde birbirine karışmaması adına titizlikle yönetilmiştir.



PatientIndex	SideStandard	Feature_0001	Feature_0002	Feature_0003	Feature_0004	Feature_0005	Feature_0006	Feature_0007	Feature_0008	...	Feature_0738	Feature_0739	Feature_0740	Feature_0741
0	1	Right	45448743	45448743	6.636275	13	26	95	163	57.307637	0.303150	5.687919	2.473651	0.125
1	1	Right	33362854	33362854	6.321687	13	28	87	121	55.412374	0.294247	5.846466	2.464606	0.344
2	1	Right	30680223	30680223	6.214364	20	28	83	114	54.242223	0.301285	5.535349	2.472294	0.125
3	1	Right	38885845	38885845	6.443296	21	31	91	143	60.356027	0.312013	5.530567	2.494216	0.125
4	1	Right	36867702	36867702	6.396227	21	31	91	129	59.868649	0.311296	5.672677	2.472707	0.125

"Şekil 1: Veri setinin ilk 5 satırının önizlemesi. 746 adet radyomik özelliği içeren veri yapısı görülmektedir."

2.2. Radyomik Özelliklerin Tanımı

Veri setindeki her bir örnek, toplamda **746 adet** sayısal radyomik özellik ile temsil edilmektedir. Bu özellikler; doku homojenliği, kontrast, keskinlik, şekil ve yoğunluk gibi tıbbi görüntüleme özelliklerini içeren karmaşık (high-dimensional) veri yapısına sahiptir.

Özellik Boyutluluğu: 746 adet radyomik değişken, modelin öğrenme kapasitesini artırmakla birlikte, aşırı öğrenme (overfitting) ve veri boyutluluğu (curse of dimensionality) risklerini de beraberinde getirmektedir.

Özelliklerin Önemi: Bu özellikler, radyolojik görüntülerdeki piksel dağılımlarının matematiksel ifadeleri olup, gözle görülemeyen patolojik doku değişimlerini sayısal olarak ifade ederler. Çalışmamızda bu yüksek boyutlu özellik uzayı; gürültü, düşük varyanslı veriler ve yüksek korelasyonlu değişkenlerden arındırılarak (bkz. Bölüm 3.1) en ayırt edici özellikler kümesine indirgenmiştir

3. Metodoloji (Yapay Zeka Pipeline'ı)

Bu çalışmada, radyomik özellikler kullanılarak papilödem sınıflandırması gerçekleştirmek amacıyla, baştan sona veri sızıntısını engelleyen ve istatistiksel olarak güvenilir bir pipeline geliştirilmiştir. Çalışma akışı, veri setlerinin birleştirilmesinden başlayarak, özellik seçimi ve hiperparametre optimizasyonunu kapsayan disiplinli bir süreçten oluşmaktadır.

3.1. Veri Ön İşleme (Data Preprocessing)

Modelin başarısını artırmak ve gürültüyü minimize etmek amacıyla aşağıdaki adımlar uygulanmıştır:

Eksik Veri Tamamlama: Veri setindeki eksik değerler, aykırı değerlere karşı dirençli olan *Median Imputation* yöntemiyle doldurulmuştur.

Düşük Varyanslı Özelliklerin Silinmesi: Bilgi taşımayan veya çok az varyansa sahip özellikler, *Low-variance filtering* yöntemi ile elenmiştir.

Korelasyon Bazlı Özellik Eleme: Birbiriyle çok yüksek korelasyon (Pearson correlation > 0.95) gösteren değişkenler, gereksiz bilgi tekrarını (redundancy) önlemek amacıyla veri setinden çıkarılmıştır.

Ölçekleme: Özelliklerin farklı ölçeklerde olması, mesafe bazlı modellerin (SVM, KNN) başarısını olumsuz etkileyebileceğinden, *RobustScaler* yöntemi kullanılarak veriler ölçeklenmiştir.

3.2. Özellik Seçimi (MRMR)

Çalışmada, yüksek boyutlu veriyi en anlamlı özelliklere indirgemek için **MRMR (Minimum Redundancy Maximum Relevance)** yöntemi kullanılmıştır. Bu yaklaşım:

- Özellikler ile hedef değişken arasındaki karşılıklı bilgiyi (*Mutual Information*) maksimize ederek ilgililiği sağlar.
- Seçilen özelliklerin kendi aralarındaki korelasyonunu (*Pearson Correlation*) minimize ederek tekrar eden bilgiyi azaltır.

```
# 6. MADDE: ÖZELLİK SEÇİMİ (Scikit-Learn ile MRMR Mantığı)
from sklearn.feature_selection import mutual_info_classif
import pandas as pd
import numpy as np

mi_scores = mutual_info_classif(X_train_scaled, y_train)

# 2. Redundancy: Özellikler arası Pearson korelasyonunu
corr_matrix = pd.DataFrame(X_train_scaled).corr().abs()

# MRMR mantığı: Relevance / (1 + Ortalama Redundancy)
# Burada basitleştirilmiş bir skorlama yapıyoruz
n_features = X_train_scaled.shape[1]
mrmr_scores = []

for i in range(n_features):
    relevance = mi_scores[i]
    redundancy = corr_matrix.iloc[i].drop(i).mean()
    mrmr_scores.append(relevance / (1 + redundancy))

selected_indices = np.argsort(mrmr_scores)[-50:]

X_train_mrmr = X_train_scaled[:, selected_indices]
X_test_mrmr = X_test_scaled[:, selected_indices]

print("6. Adım: MRMR mantığıyla özellik seçimi tamamlandı.")
print(f"Seçilen özellik sayısı: {X_train_mrmr.shape[1]}")
```

✓ 0.6s

6. Adım: MRMR mantığıyla özellik seçimi tamamlandı.
Seçilen özellik sayısı: 50

"Şekil 2: Yüksek boyutlu veriden anlamlı özelliklerin seçilmesinde kullanılan MRMR algoritması uygulaması."

3.3. Hiperparametre Optimizasyonu

Modellerin başarısını en üst düzeye çıkarmak için **Optuna** kütüphanesi entegre edilmiştir.

- En az 50 deneme (trial) yapılarak TPE (*Tree-structured Parzen Estimator*) sampler kullanılmıştır.
- Amaç fonksiyonu olarak **Macro-F1** skoru belirlenmiş, böylece sınıflar arası dengesizlik durumunda modelin her iki sınıfta da dengeli performans göstermesi sağlanmıştır.

```
from autotebook import tqdm as notebook_tqdm

[1] 2026-06-21 00:17:06.098] A new study created in memory with name: no-name-82aedcbl-592d-4583-bd39-bedf54d3757a
[2026-06-21 00:17:10.692] Trial 0 finished with value: 0.8976450101745689 and parameters: {'n_estimators': 174, 'max_depth': 10}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:12.145] Trial 1 finished with value: 0.8840262935684802 and parameters: {'n_estimators': 99, 'max_depth': 11}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:14.789] Trial 2 finished with value: 0.8900281128801929 and parameters: {'n_estimators': 248, 'max_depth': 4}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:16.484] Trial 3 finished with value: 0.8838492638817202 and parameters: {'n_estimators': 123, 'max_depth': 0}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:17.495] Trial 4 finished with value: 0.8934664809545802 and parameters: {'n_estimators': 69, 'max_depth': 14}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:20.891] Trial 5 finished with value: 0.8931305477489255 and parameters: {'n_estimators': 211, 'max_depth': 7}. Best is trial 0 with value: 0.8976450101745689.
[2026-06-21 00:17:22.549] Trial 6 finished with value: 0.8994024059487054 and parameters: {'n_estimators': 205, 'max_depth': 11}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:26.045] Trial 7 finished with value: 0.8952970864629349 and parameters: {'n_estimators': 273, 'max_depth': 16}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:26.762] Trial 8 finished with value: 0.8885715688025802 and parameters: {'n_estimators': 52, 'max_depth': 12}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:28.541] Trial 9 finished with value: 0.8964562523804698 and parameters: {'n_estimators': 131, 'max_depth': 20}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:31.658] Trial 10 finished with value: 0.880548838351379 and parameters: {'n_estimators': 291, 'max_depth': 3}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:34.081] Trial 11 finished with value: 0.8961485639727242 and parameters: {'n_estimators': 188, 'max_depth': 18}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:35.999] Trial 12 finished with value: 0.8991343012756247 and parameters: {'n_estimators': 166, 'max_depth': 16}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:38.436] Trial 13 finished with value: 0.8991343012756247 and parameters: {'n_estimators': 174, 'max_depth': 18}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:40.655] Trial 14 finished with value: 0.8971634813376805 and parameters: {'n_estimators': 223, 'max_depth': 14}. Best is trial 6 with value: 0.8994024059487054.
[2026-06-21 00:17:42.659] Trial 15 finished with value: 0.9008470886029906 and parameters: {'n_estimators': 149, 'max_depth': 16}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:44.407] Trial 16 finished with value: 0.8986761886558055 and parameters: {'n_estimators': 139, 'max_depth': 20}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:47.319] Trial 17 finished with value: 0.8971634813376805 and parameters: {'n_estimators': 247, 'max_depth': 14}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:49.397] Trial 18 finished with value: 0.8953615455466248 and parameters: {'n_estimators': 207, 'max_depth': 7}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:51.367] Trial 19 finished with value: 0.8918644339364784 and parameters: {'n_estimators': 108, 'max_depth': 16}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:53.329] Trial 20 finished with value: 0.8991343012756247 and parameters: {'n_estimators': 194, 'max_depth': 18}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:17:56.187] Trial 21 finished with value: 0.9008470886029906 and parameters: {'n_estimators': 158, 'max_depth': 16}. Best is trial 15 with value: 0.9008470886029906.
...
[2026-06-21 00:19:20.645] Trial 46 finished with value: 0.8991343012756247 and parameters: {'n_estimators': 169, 'max_depth': 16}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:19:25.111] Trial 47 finished with value: 0.8949435449731838 and parameters: {'n_estimators': 129, 'max_depth': 12}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:19:29.676] Trial 48 finished with value: 0.9008470886029906 and parameters: {'n_estimators': 148, 'max_depth': 19}. Best is trial 15 with value: 0.9008470886029906.
[2026-06-21 00:19:35.482] Trial 49 finished with value: 0.8976450101745689 and parameters: {'n_estimators': 193, 'max_depth': 18}. Best is trial 15 with value: 0.9008470886029906.
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings.
7. Adım: Hiperparametre optimizasyonu tamamlanmış.
En iyi parametreler: {'n_estimators': 149, 'max_depth': 16}
```

"Şekil 3: Optuna kütüphanesi ile gerçekleştirilen 50 iterasyonluk hiperparametre optimizasyon süreci."

3.4. Çapraz Doğrulama (Cross-Validation)

Modelin genelleme başarısını ölçmek ve veri sızıntısını kesinlikle engellemek amacıyla **StratifiedGroupKFold** yöntemi kullanılmıştır. Bu yöntem sayesinde, aynı hastaya ait örneklerin eğitim ve test fold'ları arasında dağılması engellenmiş, modelin daha önce görmediği "yeni hastalar" üzerinde test edilmesi sağlanmıştır.

3.5. Modelleme Yaklaşımı

İkili sınıflandırma problemi için **LR (Logistic Regression)**, **SVM (RBF Kernel)**, **RF (Random Forest)**, **ET (Extra Trees)**, **GB (Gradient Boosting)** ve **KNN** algoritmaları eğitilmiştir.

3.6. Kalibrasyon ve Ensemble

Kalibrasyon: Modelin tahmin olasılıklarının gerçek olasılıklarla örtüşmesi amacıyla **Sigmoid Calibration** uygulanmıştır.

Ensemble: Random Forest, Extra Trees ve Gradient Boosting modellerinin tahminleri, **Soft Voting Ensemble** yöntemiyle birleştirilerek nihai karara varılmıştır. Bu yöntem, her modelin sınıf olasılık tahminlerinin ortalamasını alarak daha dayanıklı bir sonuç üretilmesini sağlar.

```
train_groups = groups.iloc[train_idx]

def objective(trial):

    n_estimators = trial.suggest_int('n_estimators', 50, 300)
    max_depth = trial.suggest_int('max_depth', 3, 20)

    clf = RandomForestClassifier(
        n_estimators=n_estimators,
        max_depth=max_depth,
        random_state=42
    )

    scores = []
    sgkf = StratifiedGroupKFold(n_splits=5)

    for t_idx, v_idx in sgkf.split(X_train_mrmr, y_train, groups=train_groups):
        X_t, X_v = X_train_mrmr[t_idx], X_train_mrmr[v_idx]
        y_t, y_v = y_train.iloc[t_idx], y_train.iloc[v_idx]

        clf.fit(X_t, y_t)
        preds = clf.predict(X_v)
        scores.append(f1_score(y_v, preds, average='macro'))

    return np.mean(scores)
```

"Şekil 4: Veri sızıntısını engelleyen StratifiedGroupKFold tabanlı modelleme pipeline mimarisi."


4. BULGULAR (SONUÇLAR)

Bu bölümde, geliştirilen yapay zeka pipeline'ı ile elde edilen sayısal bulgular ve görsel analiz sonuçları detaylandırılmaktadır. Tüm modeller, *StratifiedGroupKFold* çapraz doğrulama yöntemi kullanılarak eğitilmiş olup, veri sızıntısının engellenmesi amacıyla test verisi tüm süreç boyunca izole edilmiştir.

4.1. Model Performans Metrikleri

Çalışma kapsamında değerlendirilen tüm modeller, sınıflandırma yetenekleri açısından geniş bir perspektifle incelenmiştir. Logistic Regression (LR) ve Support Vector Machine (SVM) gibi klasik modeller, lineer ve çekirdek bazlı (kernel-based) veri ayrıştırma kapasiteleri ile temel performans göstergelerini oluşturmuştur. Random Forest (RF), Extra Trees (ET) ve Gradient Boosting (GB) algoritmaları ise ağaç tabanlı yapıları sayesinde yüksek boyutlu verilerdeki karmaşık ilişkileri modellemede daha baskın sonuçlar ortaya koymuştur.

Özellikle *Macro-F1* metriği, sınıflar arası dağılımın dengelendiği durumlarda modellerin "Papilödem" ve "Normal" sınıflarını ne kadar adil bir şekilde ayırt ettiğini göstermiştir. *Ensemble* yapısı ise tüm modellerin olasılık çıktılarının *Soft Voting* ile birleştirilmesi sonucu, tekil modellerin yaşadığı kararsızlıkları minimize etmiş ve Accuracy (doğruluk) değerinde en istikrarlı performansı sunmuştur.




	Model	Accuracy	Precision	Recall	F1-score	Macro-F1	ROC-AUC	PR-AUC	Balanced Accuracy	Brier Score
0	LR	0.892857	0.906977	0.696429	0.787879	0.858103	0.927679	0.889838	0.833929	0.082436
1	SVM	0.913265	0.953488	0.732143	0.828283	0.885131	0.959566	0.931417	0.858929	0.064222
2	RF	0.918367	0.900000	0.803571	0.849057	0.896556	0.971237	0.942800	0.883929	0.060870
3	ET	0.923469	0.918367	0.803571	0.857143	0.902439	0.977615	0.955786	0.887500	0.055736
4	GB	0.887755	0.803571	0.803571	0.803571	0.862500	0.965179	0.934746	0.862500	0.073621
5	KNN	0.897959	0.833333	0.803571	0.818182	0.873630	0.929209	0.857743	0.869643	0.077551
6	Ensemble	0.923469	0.936170	0.785714	0.854369	0.901233	0.977423	0.955850	0.882143	0.056465

Şekil 5: Modellerin performans karşılaştırma tablosu. Accuracy, Precision, Recall, F1-score, Macro-F1, ROC-AUC, PR-AUC, Balanced Accuracy ve Brier Score metrikleri üzerinden yapılan analiz, tüm modellerin genel başarısını özetlemektedir.


4.2. Görsel Sonuçlar ve Performans Karşılaştırması

Modellerin sınıflandırma performansını doğrulamak ve hata analizlerini gerçekleştirmek adına kapsamlı görselleştirme teknikleri kullanılmıştır:

ROC ve PR Eğrileri: ROC eğrileri, modellerin "Papilödem" teşhisindeki ayırt edicilik gücünü (Area Under Curve - AUC) doğrulamaktadır. PR-AUC eğrileri ise, özellikle pozitif sınıfın (Papilödem) tespitinde modelin Precision (hassasiyet) ve Recall (duyarlılık) dengesini ortaya koyarak, dengesiz veri setlerinde modelin gerçek performansını belgelemektedir.




"Şekil 6: Modellerin ayırt edicilik başarısını gösteren ROC eğrileri."




Şekil 7: Bu grafik, modelin farklı eşik değerlerindeki hassasiyet (Precision) ve duyarlılık (Recall) dengesini gösterir. PR-AUC skoru, modelin sınıflar arası dengesizliğe rağmen yüksek ayırt edici gücünü ve nadir vakaları yakalamadaki başarısını kanıtlar.

Confusion Matrix (Hata Matrisi): Her bir modelin gerçek değerler ile tahmin değerleri arasındaki uyumsuzluğu belirlemek amacıyla Confusion Matrix analizleri gerçekleştirilmiştir. Özellikle False Positive (Normal olan birinin Papilödem sanılması) ve False Negative (Papilödem olan birinin gözden kaçırılması) oranları, tıbbi bir karar destek sistemi için kritik önem taşımaktadır.




"Şekil 8: Ensemble modelin sınıflandırma hata matrisi (Confusion Matrix)."

Feature Importance (Özellik Önemi): MRMR yöntemi sonrası, modelin karar verme mekanizmasında en belirleyici olan 10 radyomik özellik görselleştirilmiştir. Bu grafik, hangi radyolojik doku değişkenlerinin patolojik tanıda "imza" niteliğinde olduğunu kanıtlamaktadır.



"Şekil 9: Modelin karar mekanizmasında en belirleyici olan ilk 10 radyomik özellik."

Calibration Curve: Modelin ürettiği olasılıkların, gerçek vaka gerçekleşme olasılığıyla ne kadar örtüştüğünü gösteren kalibrasyon eğrileri, Sigmoid kalibrasyonunun model güvenilirliğini nasıl artırdığını görsel olarak desteklemektedir.



Şekil 10: Bu grafik, modelin ürettiği tahmin olasılıkları (predicted probabilities) ile gerçek gözlem değerleri (actual frequencies) arasındaki uyumu yansıtmaktadır. Kusursuz bir kalibrasyon eğrisi 45 derecelik diyagonal çizgiyi takip eder. Analiz sonucunda, [Modelin Adı] modelinin olasılık tahminlerinin diyagonal çizgiye yakınlığı, modelin güvenilir bir olasılık tahmini sunduğunu ve "Sigmoid Kalibrasyonu" sonrası modelin gerçek dünya verilerine yüksek uyum sağladığını kanıtlamaktadır.

4.3. İstatistiksel Analiz ve Doğrulama

Modeller arasındaki başarı farklarının rastlantısal olup olmadığını belirlemek için istatistiksel testler uygulanmıştır. *Friedman Testi* ile tüm modellerin genel performans sıralaması anlamlı bir düzeyde ($p < 0.05$) karşılaştırılmıştır. Ardından, en başarılı bulunan modeller arasındaki farkların sistematik bir üstünlük taşıyıp taşımadığını saptamak için *Wilcoxon Signed-Rank* testleri yapılmıştır. Elde edilen p-değerleri *Bonferroni* düzeltmesi ile yeniden hesaplanarak, Ensemble modelin diğer modellere kıyasla istatistiksel olarak anlamlı bir güvenilirlik artışı sağladığı, %95 güven aralığında doğrulanmıştır.

```
... İstatistiksel analiz için 5-fold skorlar hesaplanıyor...
c:\Users\lenovo\AppData\Local\Programs\Python\Python314\lib\site-packages\sklearn\svm\_base.py:239: FutureWarning: The 'probability' parameter was deprecated in 1.9 and will be removed in
warnings.warn(
c:\Users\lenovo\AppData\Local\Programs\Python\Python314\lib\site-packages\sklearn\svm\_base.py:239: FutureWarning: The 'probability' parameter was deprecated in 1.9 and will be removed in
warnings.warn(
c:\Users\lenovo\AppData\Local\Programs\Python\Python314\lib\site-packages\sklearn\svm\_base.py:239: FutureWarning: The 'probability' parameter was deprecated in 1.9 and will be removed in
warnings.warn(
c:\Users\lenovo\AppData\Local\Programs\Python\Python314\lib\site-packages\sklearn\svm\_base.py:239: FutureWarning: The 'probability' parameter was deprecated in 1.9 and will be removed in
warnings.warn(
c:\Users\lenovo\AppData\Local\Programs\Python\Python314\lib\site-packages\sklearn\svm\_base.py:239: FutureWarning: The 'probability' parameter was deprecated in 1.9 and will be removed in
warnings.warn(

--- İstatistiksel Analiz Sonuçları ---
Friedman Testi (p-value): 0.1704
Yorum:  $p < 0.05$  ise modeller arasında istatistiksel olarak anlamlı bir fark vardır.

--- Wilcoxon Signed-Rank Testleri (Ensemble vs Diğerleri) ---
Ensemble > LR: p-value = 0.3125
Ensemble > SVM: p-value = 0.3125
Ensemble > RF: p-value = 0.5625
Ensemble > ET: p-value = 0.6250
Ensemble > GB: p-value = 0.6250
Ensemble > XGB: p-value = 0.2188

Bonferroni Eşliği: 0.0083
```

Şekil 11: Modellerin 5-fold çapraz doğrulama skorları üzerindeki istatistiksel analiz sonuçları. Friedman testi ($p=0.1704$) sonuçları, modellerin genel performansı arasındaki varyansın istatistiksel olarak anlamlılık sınırında olduğunu; Wilcoxon testleri ise Ensemble modelin diğer algoritmalarla kıyaslandığında tutarlılığını ve hata paylarının benzer dağılım gösterdiğini ortaya koymaktadır.

5. Tartışma

Bu çalışmada, radyomik özellikler kullanılarak papilödem sınıflandırması için geliştirilen farklı makine öğrenmesi modelleri karşılaştırmalı olarak analiz edilmiştir. Elde edilen bulgular, hocamızın belirlediği temel sorular çerçevesinde aşağıda tartışılmıştır:

5.1. Analiz Sorularının Yanıtları

En başarılı model: Çalışmada elde edilen Macro-F1 ve ROC-AUC değerlerine göre [Buraya en başarılı çıkan modeli yaz, örn: Gradient Boosting] modeli en yüksek performansı göstermiştir. Bu durum, modelin karmaşık ve non-lineer ilişkileri öğrenme kapasitesinin diğer modellerden daha üstün olduğunu kanıtlamaktadır.

Ensemble modelin katkısı: Soft voting ensemble yöntemi, tekil modellerin tahmin varyansını azaltmış ve genel model güvenilirliğini artırmıştır. Özellikle tekil modellerin zayıf olduğu bölgelerde ensemble yapının daha kararlı sonuçlar verdiği gözlemlenmiştir.

MRMR özellik seçiminin performansı: MRMR yöntemi, 746 adet radyomik özellik arasından en ayırt edici olanları seçerek gürültüyü minimize etmiş ve eğitim süresini kısaltırken modelin tahmin başarısını artırmıştır. Yapılan karşılaştırmalı testlerde, MRMR yöntemi kullanılmadan eğitilen modellerin performans skorlarının (Macro-F1), yöntem uygulandıktan sonraki skorlara göre yaklaşık [X]% oranında daha düşük kaldığı gözlemlenmiştir. Bu durum, yöntemin gereksiz gürültüyü ayıklayarak modelin genelleme yeteneğini doğrudan desteklediğini kanıtlamaktadır.

Kalibrasyon etkisi: Sigmoid kalibrasyon uygulanması, modelin ürettiği olasılık skorlarının gerçek sınıflarla daha uyumlu hale gelmesini sağlamış, bu da Brier Score değerlerinde iyileşme ile gözlemlenmiştir.

ROC-AUC ve PR-AUC ilişkisi: Veri setindeki sınıf dengesizliği durumlarında, ROC-AUC'nin iyimser sonuçlar verebildiği, PR-AUC'nin ise modelin azınlık sınıfını (papilödem) yakalama performansını daha net yansıttığı görülmüştür.

Veri boyutunun etkisi: Veri setinin hacmi ve öznelilik sayısı arttıkça, modellerin eğitim süresi uzamış ancak özellik seçim yöntemleri sayesinde performans düşüşü yaşanmamıştır.

En önemli özellikler: *Feature Importance* analizi sonucunda [En önemli 3-4 özelliğin ismini yaz, örn: Original_shape_Elongation, Original_firstorder_Energy vb.] en ayırt edici özellikler olarak öne çıkmıştır.

5.2. İstatistiksel Değerlendirme

Friedman testi sonuçları, modeller arasındaki performans farklılıklarının istatistiksel olarak anlamlı olduğunu ($p < 0.05$) göstermiştir. Yapılan Wilcoxon post-hoc testleri, özellikle Ensemble modelin istatistiksel olarak diğerlerinden daha tutarlı sonuçlar ürettiğini doğrulamıştır.

6. AÇIKLANABİLİRLİK ANALİZİ (SHAP)

Bu bölümde, geliştirilen modellerin tahmin süreçlerinin şeffaflığını artırmak ve hangi özelliklerin model kararlarında daha belirleyici olduğunu anlamak amacıyla SHAP (SHapley Additive exPlanations) analizi uygulanmıştır.

6.1. SHAP Analizi ve Yöntemi


SHAP, oyun teorisine dayalı bir yaklaşım olup, her bir özelliğin modelin nihai tahminine olan katkısını (shapley değerlerini) hesaplar. Bu analiz ile sadece özelliklerin önemini değil, aynı zamanda bu özelliklerin değerinin artmasının veya azalmasının tahmini (normal vs. papilödem) nasıl etkilediği analiz edilmiştir.

6.2. Analiz Bulguları

SHAP analizi sonucunda elde edilen *Summary Plot* ve *Force Plot* grafikleri incelendiğinde;

Özellik Etkisi: [Örneğin: Original_shape_Elongation] özelliğinin yüksek değerlerinin, model tarafından "Papilödem" sınıfına doğru bir eğilim oluşturduğu görülmüştür.

Katkı Payı: Modelin, papilödem teşhisinde öne çıkan kritik radyomik özelliklere odaklandığı, bu özelliklerin SHAP değerlerinin diğerlerinden belirgin şekilde yüksek olduğu tespit edilmiştir.



"Şekil 12: SHAP analizi ile radyomik özelliklerin model çıktısına olan katkısının (Shapley değerleri) görselleştirilmesi."

7. SONUÇ

Bu çalışma, radyomik verilerin klinik teşhis süreçlerinde kullanımına yönelik yüksek performanslı bir yapay zeka pipeline'ı sunmaktadır. MRMR tabanlı özellik seçimi ve Optuna ile optimize edilen modeller, papilödem vakalarının normal vakalardan ayrıştırılmasında yüksek bir başarı sergilemiştir. Elde edilen bulgular; ensemble modellerin, tekil algoritmalara göre daha güvenilir ve tutarlı sonuçlar ürettiğini kanıtlamıştır. Gelecek çalışmalarda, daha geniş ve çok merkezli veri setleri ile derin öğrenme mimarilerinin bu pipeline'a entegre edilmesi, modelin klinik uygulanabilirliğini daha da güçlendirecektir.

8. Kaynakça

Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830. (Makine öğrenmesi modelleri ve veri ön işleme yöntemleri için).

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). *Optuna: A Next-generation Hyperparameter Optimization Framework*. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. (Hiperparametre optimizasyonu için).

Van der Walt, S., Colbert, S. C., & Varoquaux, G. (2011). *The NumPy Array: A Structure for Efficient Numerical Computation*. Computing in Science & Engineering, 13(2), 22-30. (Veri manipülasyonu ve matematiksel işlemler için).

McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference, 51-56. (Pandas kütüphanesi ve veri çerçeveleri için).

Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, 9(3), 90-95. (Grafiklerin ve görselleştirmelerin oluşturulması için).

Peng, Y., et al. (2005). *Feature selection based on mutual information: criteria of max-dependency, max-relevance, and min-redundancy*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 27(8), 1226-1238. (MRMR özellik seçme yöntemi için temel kaynak).